



실습 3강 k평균 군집분석

실습 데이터

- ❖ 실습데이터와 실습과정은 Brett Lantz, “Machine Learning with R”에서 발췌
- ❖ 미국 10대 학생들의 소셜 네트워크 프로파일 데이터를 이용한 군집분석
- ❖ 30,000명 (여학생 비율 74%)
- ❖ 40개 변수 활용

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	dar
1	gradyear	gender	age	friends	basketball	football	soccer	softball	volleyball	swimming	cheerlead	baseball	tennis	sports	cute	sex	sexy	hot	kissed	dar
2	2006	M	18.982	7	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
3	2006	F	18.801	0	0	1	0	0	0	0	0	0	0	0	0	1	0	0	0	0
4	2006	M	18.335	69	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0
5	2006	F	18.875	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0
6	2006	NA	18.995	10	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	5
7	2006	F		142	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0
8	2006	F	18.93	72	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
9	2006	M	18.322	17	0	0	0	1	0	0	0	0	0	0	0	0	2	1	0	0
10	2006	F	19.055	52	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
11	2006	F	18.708	39	0	0	0	0	0	0	0	0	0	0	0	1	0	0	1	0
12	2006	F	18.543	8	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
13	2006	F	19.463	21	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0

데이터 구조 확인

데이터 읽기

```
teens <- read.csv("snsdata.csv")
```

구조 확인

```
str(teens)
```

```
'data.frame': 30000 obs. of 40 variables:
 $ gradyear      : int  2006 2006 2006 2006 2006 2006...
 $ gender        : Factor w/ 2 levels "F","M": 2 1 2 1 NA 1 ...
 $ age           : num  19 18.8 18.3 18.9 19 ...
 $ friends       : int  7 0 69 0 10 142 72 17 52 39 ...
 $ basketball    : int  0 0 0 0 0 0 0 0 0 0 ...
 $ football      : int  0 1 1 0 0 0 0 0 0 0 ...
 $ soccer        : int  0 0 0 0 0 0 0 0 0 0 ...
 $ softball      : int  0 0 0 0 0 0 0 1 0 0 ...
 $ volleyball    : int  0 0 0 0 0 0 0 0 0 0 ...
```

결측치

데이터 구조 확인

❖ 데이터 확인

```
# female 변수의 결측 데이터 확인  
table(teens$gender)
```

```
# 결측값을 포함할 수 있도록 ifany 작성  
table(teens$gender, useNA = "ifany")
```

```
> table(teens$gender)
```

F	M
22054	5222

```
> table(teens$gender, useNA = "ifany")
```

F	M	<NA>
22054	5222	2724

데이터 구조 확인

age 변수의 결측 데이터 확인
summary(teens\$age)

```
> summary(teens$age)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.	NA's
3.086	16.312	17.287	17.994	18.259	106.927	5086

이상치
(Outlier)

데이터 구조 확인

❖ 이상치 (Outliers) 제거

- 연령이 13세 이상 20세 미만이면 `teen$age`에 값을 대입하고, 아닐 경우에는 NA로 대체

```
# age 이상치(outliers) 제거
```

```
teens$age <- ifelse(teens$age >= 13 & teens$age < 20,  
                    teens$age, NA)
```

```
# age 변수의 데이터 확인
```

```
summary(teens$age)
```

```
> summary(teens$age)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.	NA's
13.03	16.30	17.27	17.25	18.22	20.00	5523

데이터 구조 확인

❖ 결측치 더미 코딩

- 남녀가 있을 때, 여자와 결측치가 있을 경우 → 최종 결측치를 남자로 추정함

"unknown"인 성별값에 재부여

```
teens$female <- ifelse(teens$gender == "F" &  
                      !is.na(teens$gender), 1, 0)
```

```
teens$no_gender <- ifelse(is.na(teens$gender), 1, 0)
```

데이터 구조 확인

❖ 데이터 확인

재지정한 작업에 대한 확인

```
table(teens$gender, useNA = "ifany")  
table(teens$female, useNA = "ifany")  
table(teens$no_gender, useNA = "ifany")
```

```
> table(teens$gender, useNA = "ifany")
```

F	M	<NA>
22054	5222	2724

```
> table(teens$female, useNA = "ifany")
```

0	1
7946	22054

```
> table(teens$no_gender, useNA = "ifany")
```

0	1
27276	2724

데이터 구조 확인

❖ 결측치 대체

- 졸업세대의 대표 연령을 식별할 수 있도록 나이를 추정

```
# 집단(cohort)별 나이 평균  
mean(teens$age) # doesn't work  
mean(teens$age, na.rm = TRUE)
```

```
> mean(teens$age) # doesn't work  
[1] NA
```

```
> mean(teens$age, na.rm = TRUE)  
[1] 17.25243
```

데이터 구조 확인

집단별 나이

```
aggregate(data = teens, age ~ gradyear, mean, na.rm = TRUE)
```

```
> aggregate(data = teens, age ~ gradyear, mean, na.rm = TRUE)
```

	gradyear	age
1	2006	18.65586
2	2007	17.70617
3	2008	16.76770
4	2009	15.8195

각 개인에 대한 예측된 나이 계산

```
ave_age <- ave(teens$age, teens$gradyear,  
              FUN = function(x) mean(x, na.rm = TRUE))
```

```
teens$age <- ifelse(is.na(teens$age), ave_age, teens$age)
```



데이터 구조 확인

❖ 결측치 요약 확인

제거한 결측치에 대한 요약 결과 확인
`summary(teens$age)`

➤ `summary(teens$age)`

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
13.03	16.28	17.24	17.24	18.21	20.00

Clustering syntax

using the `kmeans()` function in the `stats` package

Finding clusters:

```
myclusters <- kmeans(mydata, k)
```

- `mydata` is a matrix or data frame with the examples to be clustered
- `k` specifies the desired number of clusters

The function will return a cluster object that stores information about the clusters.

Examining clusters:

- `myclusters$cluster` is a vector of cluster assignments from the `kmeans()` function
- `myclusters$centers` is a matrix indicating the mean values for each feature and cluster combination
- `myclusters$size` lists the number of examples assigned to each cluster

Example:

```
teen_clusters <- kmeans(teens, 5)  
teens$cluster_id <- teen_clusters$cluster
```

kmeans 문법 구조

❖ 모델 만들기

```
myclusters <- kmeans(mydata, k)
```



```
teen_clusters <- kmeans(interests_z, 5)
```

- mydata : 군집화 될 예시가 있는 행렬 또는 데이터 프레임
- k : 희망 클러스터의 개수

❖ 클러스터 분석

- 다양한 관심사의 횟수를 표현하는 36개의 특징만을 고려하여 클러스터 분석 시작

```
set.seed(2345)
```

```
interests <- teens[5:40]
```

```
interests_z <- as.data.frame(lapply(interests, scale))
```

```
teen_clusters <- kmeans(interests_z, 5)
```



❖ 모델의 성능을 평가하기 위해 kmeans 함수의 속성 이용

```
# 군집의 크기 확인  
teen_clusters$size
```

```
> teen_clusters$size  
[1] 1038    601   4066   2696  21599
```

※ kmeans 의 클러스터 속성

- \$cluster : kmeans() 함수에서 얻은 클러스터 할당 벡터
- \$centers : 각 특징과 클러스터 조합별로 평균값을 나타내는 행렬
- \$size : 각 클러스터에 할당된 예시 개수

분석 결과 확인

군집의 중앙점(centers) 확인 teen_clusters\$centers

```
> teen_clusters$centers
```

	basketball	football	soccer	softball	volleyball	swimming	cheerleading	baseball	tennis	
1	0.362160730	0.37985213	0.13734997	0.1272107	0.09247518	0.26180286	0.2159945	0.25312305	0.11991682	
2	-0.094426312	0.06691768	-0.09956009	-0.0379725	-0.07286202	0.04578401	-0.1070370	-0.11182941	0.04027335	
3	0.003980104	0.09524062	0.05342109	-0.0496864	-0.01459648	0.32944934	0.5142451	-0.04933628	0.06703386	
4	1.372334818	1.19570343	0.55621097	1.1304527	1.07177211	0.08513210	0.0400367	1.09279737	0.13887184	
5	-0.186822093	-0.18729427	-0.08331351	-0.1368072	-0.13344819	-0.08650052	-0.1092056	-0.13616893	-0.03683671	
	sports	cute	sex	sexy	hot	kissed	dance	band	marching	
1	0.77040675	0.475265034	2.043945661	0.547956598	0.314845390	3.02610259	0.455501275	0.39009330	-0.0105463	
2	-0.10638613	-0.027044898	-0.042725567	-0.027913348	-0.035027022	-0.04581067	0.050772118	4.09723438	5.2196105	
3	-0.05435093	0.796948359	-0.003156716	0.266741598	0.623263396	-0.01284964	0.650572336	-0.03301257	-0.1131486	
4	1.08316097	-0.005291962	-0.033193640	0.003036966	0.009046774	-0.08755418	-0.001993853	-0.07317758	-0.1039509	
5	-0.15903307	-0.171452198	-0.092301138	-0.076149916	-0.132614350	-0.13080557	-0.145524147	-0.11740538	-0.1104553	
	music	rock	god	church	jesus	bible	hair	dress	blonde	mall
1	1.21014015	1.2014998	0.41743650	0.1621804	0.12698409	0.07464400	2.59053048	0.5312082	0.36322464	0.622896285
2	0.51624366	0.1865286	0.09706027	0.0675347	0.05333966	0.05836708	-0.05146837	0.0492724	-0.01238629	-0.087713363
3	0.24527495	0.1166274	0.32867738	0.5195729	0.26142784	0.23946855	0.35590025	0.5837827	0.03301526	0.808620531
4	0.07102323	0.1565155	0.04902918	0.1320602	0.01776986	0.01719220	0.01714820	-0.0653358	0.03690938	-0.004723697
5	-0.12755935	-0.1044230	-0.09075500	-0.1239664	-0.05901846	-0.05243708	-0.19220150	-0.1286412	-0.02793327	-0.179127117
	shopping	clothes	hollister	abercrombie	die	death	drunk	drugs		
1	0.27607550	1.245121599	0.31525537	0.4131560	1.712160983	0.94713629	1.83371069	2.73878856		
2	-0.03710273	-0.004395251	-0.16788599	-0.1413652	0.008941101	0.05464759	-0.08699556	-0.06414588		
3	1.07073115	0.616207360	0.85951603	0.7935060	0.062399295	0.12642222	0.03594162	-0.05888141		
4	0.03497875	0.016201064	-0.08381546	-0.0861708	-0.067312427	-0.01611162	-0.06891763	-0.08795059		
5	-0.21816580	-0.177738408	-0.16182051	-0.1545430	-0.085876102	-0.06882571	-0.08386703	-0.10777278		

분석 결과 확인

군집의 중앙점(centers) 확인
teen_clusters\$centers

```
> teen_clusters$centers
```

	basketball	football	soccer	softball	volleyball	swimming						
1	0.16001227	0.2364174	0.10385512	0.07232021	0.18897158	0.23970234						
2	-0.09195886	0.0652625	-0.09932124	-0.01739428	-0.06219308	0.03339844						
3	0.52755083	0.4873480	0.29778605	0.37178877	0.37986175	0.29628671						
4	0.34081039	0.3593965	0.12722250	0.16384661	0.11032200	0.26943332						
5	-0.16695523	-0.1641499	-0.09033520	-0.11367669	-0.11682181	-0.10595448						
	cheerleading	baseball	tennis	sports	cute	sex						
1	0.3931445	0.02993479	0.13532387	0.10257837	0.37884271	0.020042068						
2	-0.1101103	-0.11487510	0.04062204	-0.09899231	-0.03265037	-0.042486141						
3	0.3303485	0.35231971	0.14057808	0.32967130	0.54442929	0.002913623						
4	0.1856664	0.27527088	0.10980958	0.79711920	0.47866008	2.028471066						
5	-0.1136077	-0.10918483	-0.05097057	-0.13135334	-0.18878627	-0.097928345						
	sexy	hot	kissed	dance	band	marching	music					
1	0.11740551	0.41389104	0.06787768	0.22780899	-0.10257102	-0.10942590	0.1378306					
2	-0.04329091	-0.03812345	-0.04554933	0.04573186	4.06726666	5.25757242	0.4981238					
3	0.24040196	0.38551819	-0.03356121	0.45662534	-0.02120728	-0.10880541	0.2844999					
4	0.51266080	0.31708549	2.97973077	0.45535061	0.38053621	-0.02014608	1.1367885					
5	-0.09501817	-0.13810894	-0.13535855	-0.15932739	-0.12167214	-0.11098063	-0.1532006					

분석 결과 확인

❖ 결과 해석

Cluster 1 (N = 3,376)	Cluster 2 (N = 601)	Cluster 3 (N = 1,036)	Cluster 4 (N = 3,279)	Cluster 5 (N = 21,708)
swimming cheerleading cute sexy hot dance dress hair mall hollister abercrombie shopping clothes	band marching music rock	basketball football soccer softball volleyball baseball sports god church Jesus bible	sports sex sexy hot kissed dance music band die death drunk drugs	???
Princesses	Brains	Athletes	Criminals	Basket Cases

분석 결과 확인

❖ 결과 해석

```
# 본래 데이터 프레임에 군집ID(cluster ID) 적용  
teens$cluster <- teen_clusters$cluster
```

```
# 처음 5개 데이터 확인  
teens[1:5, c("cluster", "gender", "age", "friends")]
```

```
> teens[1:5, c("cluster", "gender", "age", "friends")]
```

	cluster	gender	age	friends
1	5	M	18.982	7
2	3	F	18.801	0
3	5	M	18.335	69
4	5	F	18.875	0
5	1	<NA>	18.995	10

분석 결과 확인

군집 별 평균 나이

```
aggregate(data = teens, age ~ cluster, mean)
```

```
> aggregate(data = teens, age ~ cluster, mean)
```

	cluster	age
1	1	17.09319
2	2	17.38488
3	3	17.03773
4	4	17.03759
5	5	17.30265

군집 별 여성 비율

```
aggregate(data = teens, female ~ cluster, mean)
```

```
> aggregate(data = teens, female ~ cluster, mean)
```

	cluster	female
1	1	0.8025048
2	2	0.7237937
3	3	0.8866208
4	4	0.6984421
5	5	0.7082735

분석 결과 확인

군집 별 친구 수의 평균

```
aggregate(data = teens, friends ~ cluster, mean)
```

```
> aggregate(data = teens, friends ~ cluster, mean)
```

	cluster	friends
1	1	30.66570
2	2	32.79368
3	3	38.54575
4	4	35.91728
5	5	27.79221